

<b>i</b>	0	1	2	3	4	5	6	7	8	9	10	11	12	13	14
<b>s[]</b>	a	a	a	a	a	b	z	a	a	a	a	a	a	b	y
<b>z[]</b>	0	4	3	2	1	0	0	5	6	4	3	2	1	0	0

**Z[i]** = tamanho do maior prefixo comum entre **s** e o sufixo que começa em **i**, **s[i, n - 1]**;

**Naive  $O(n^2)$ :**

```
vector<int> naive_z_function(const string &s) {
    int n = s.size();
    vector<int> z(n, 0);
    for(int i = 1; i < n; i++) {
        while(i + z[i] < n && s[z[i]] == s[i + z[i]]) {
            z[i]++;
        }
    }
    return z;
}
```

*Z function naive :  $O(n^2)$*

Ideia naive: para cada sufixo começando em  $i = 1$  até  $i = n - 1$ , inicia-se  $z[i] = 0$ . Podemos aumentar o tamanho atual de  $z[i]$  se e somente se  $(i + z[i]) < n$  e o caractere atual sendo comparado de fato bate com o prefixo respectivo:  $s[i + z[i]] == s[z[i]]$ ;

## Z-function

A ideia central do algoritmo guarda a essência do algoritmo naive, mas com a definição fundamental dos ponteiros **[L, R]**.

Considere que estamos interessados em calcular **z[i]** para algum  $i > 0$ .

Definimos **R**: O índice do fim do sufixo de **S**, que termina mais à direita possível de **i**, e que também é prefixo de S. Este sufixo deve começar ESTRITAMENTE ANTES de **i**.

Definimos **L**: O índice do começo do de **S**, que termina mais à direita possível de **i** e que também é prefixo de S. Este sufixo deve começar ESTRITAMENTE ANTES de **i**.

Portanto temos: Para um dado **i**, **R = max R** tal que  $1 \leq L < i \leq R \leq n - 1$ , **S[L, R]** é um prefixo de **S**.

**Por que os ponteiros [L, R] são úteis?**

A explicação a seguir resolve o problema de calcular  $z[i]$  para o  $i$ -ésimo índice da string. É assumido que calculamos corretamente todos os valores de  $z[j < i]$  e os valores adequados de  $L, R, 1 \leq L, R \leq n - 1$ , anteriores à  $i$ .

### Caso $L < i \leq R$

O primeiro caso é quando  $1 \leq L < i \leq R$ .

A primeira observação é que a substring  $S[L, R]$ ,  $L > 0$ , é um prefixo de tamanho  $R - L + 1$ , ou seja a string  $S[L, R]$  é igual a string  $S[0, R - L]$ .

A segunda observação importante é que como  $L < i \leq R$ , a string  $S[i, R]$  também já apareceu anteriormente, pois ela está dentro de  $S[L, R]$ , que já apareceu antes. Portanto, podemos aproveitar essa resposta para calcular  $z[i]$ .

i	0	1	2	3	4	5	6	7	i = 8	9
s[]	a	b	a	c	a	b	a	b	a	c
z[]	0	0	1	0	3	0	4	0	1	0
							L = 6			
								R = 9		

Tabela: exemplo da segunda observação:

Considere que estamos interessados em calcular  $z[i = 8]$ ,  $i = 8$ . Temos que  $L = 6$ ,  $R = 9$ , e portanto a substring  $s[8, 9] = "ac"$  já apareceu antes em  $s[2, 3] = "ac"$ , portanto  $z[8] = z[2] = 1$ .

Note que NÃO necessariamente a resposta final de  $z[i]$  vai ser  $\min(R - L + 1, z[i - L])$ , pois ainda podemos aumentar  $z[i]$  caso  $S[i + z[i]] == S[z[i]]$ .

Precisamos da função **min()** porque pode ser que  $z[i - L] < (R - L + 1)$ .

Por exemplo:

i	0	1	2	3	4	5	6	7	8
s[]	a	a	a	b	x	a	a	a	b
z[]	0	2	1	0	0	4	2 (Caso $z[i - L] < (R - L + 1)$ )	1	0
						L = 5 R = 8			

Tabela: exemplo de como  $z[i - L]$  pode ser MENOR que  $(R - L + 1)$

No caso de  $S[i + z[i]] == S[z[i]]$  depois de fazer  $z[i] = \min(R - L + 1, z[i - L])$  é necessário continuar calculando  $z[i]$  conforme o algoritmo naive, e atualizar o valor de  $[L, R]$  conforme o caso.

Segue um exemplo de onde é necessário continuar o cálculo de  $z[i]$ .

i	0	1	2	3	4	5	6	7
s[]	a	a	b	a	a	a	b	d
z[]	0	1	0	2	3	1	0	0
				L = 3 R = 4	Caso $z[i] > (R - L + 1)$			

Tabela: exemplo de como  $z[i]$  pode ser MAIOR que  $(R - L + 1)$

**Exemplo:**

**Caso  $R > i$ .**

Isso quer dizer que não existe nenhum sufixo começando em  $1 \leq L < i$  e terminando em  $R \geq i$ . Neste caso, calculamos  $z[i]$  da forma naive. Após isso,  $L = i$ ,  $R = i + z[i] - 1$

```
vector<int> z_function(const string &s) {
    int n = s.size();
    vector<int> z(n, 0);
    int L = 0, R = 0;
    for(int i = 1; i < n; i++) {
        if(i <= R) {
            z[i] = min(z[i - L], R - i + 1);
        }
        while(z[i] + i < n && s[z[i] + i] == s[z[i]]) {
            z[i]++;
        }
        if(R < i + z[i] - 1) {
            L = i, R = i + z[i] - 1;
        }
    }
    return z;
}
```

**Complexidade**

**O(n)**

## **Aplicações**

Aplicação 1:

String matching: dado **text** e **pat** queremos saber o número de ocorrências de **pat** em **text**.  
Fazemos **z = z\_function(pat + “#” + text)** onde “#” é uma letra que não pertence a **pat** e nem a **text**.

As ocorrências de **pat** em **text** se dão onde **z[i] = |pat|**.

Aplicação 2

Matching com caracteres contíguos diferentes:

Neste problema ao compararmos duas strings de tamanhos iguais, podemos considerar “match” se houveram até **k** mismatches tais que os **k** mismatches ocorreram de forma contígua.

Ex:

AABC

AXBC (mismatch de 1)

AAZE

XXZE (mismatch de 2)

ABCD

DCBA (mismatch de 4)

## **Solução**

Montemos

**Z = z\_function(pat + “#” + text);**

**Z\_rev = z\_function(rev(pat) + “#” + rev(text));**

Para saber o mismatch contíguo entre **pat** e a **text[i]**,  $i \leq n - m$ , basta fazer:

**Mismatch = m - (Z[i + m + 1] - z\_rev[n - i + 1])**

## Referências

[https://github.com/edsomjr/TEP/blob/master/Strings/text/Algoritmos\\_de\\_Busca.md](https://github.com/edsomjr/TEP/blob/master/Strings/text/Algoritmos_de_Busca.md)

[http://e-maxx.ru/algo/z\\_function](http://e-maxx.ru/algo/z_function) (utilize <https://translate.yandex.com/translate> para traduzir)

<http://codeforces.com/blog/entry/3107>